

Sistema de Detecção de Estados Operacionais de Equipamentos Industriais utilizando Machine Learning

Trabalho de Conclusão de Curso

Felipe Costa Lopes

Matrícula: 2018019648

Orientadora: Profa. Dra. Gabriela Nunes

Universidade Federal de Minas Gerais

9 de junho de 2026

- ① Introdução
- ② Metodologia
- ③ Resultados
- ④ Conclusão

Contextualização: equipamentos “caixa preta”

Situação real:

- Muitos equipamentos operam como “caixas pretas”.
- O estado real (ligado/desligado) não chega à infraestrutura IoT.

Consequências:

- Ciclo operacional desconhecido.
- Indicadores de produção e manutenção imprecisos.
- Soluções tradicionais não escalam para a diversidade de plantas.

Por que não simplesmente definir limiares fixos?

Ideia ingênua: vibração ≈ 0 e corrente $\approx 0 \Rightarrow$ DESLIGADO.

Problemas na prática:

- **Cada equipamento é único:** uma motobomba de 125 cv vibra a ~ 8 mm/s em operação; um mancal opera abaixo de 1 mm/s. O mesmo limiar fixo classificaria ambos errado.
- **Desgaste natural:** após 1 ano de uso o mesmo equipamento, em plenas condições, pode vibrar 20% a mais. Um limiar fixo começa a classificar estado LIGADO como DESLIGADO.
- **Ambiente não controlado:** vibração de máquinas vizinhas, sazonalidade térmica e interferências eletromagnéticas sobrepõem-se ao sinal real, deslocando a “linha de base”.

Meta principal

Desenvolver um sistema **não invasivo** e **automático** capaz de detectar os estados LIGADO/DESLIGADO de equipamentos industriais, utilizando **exclusivamente** os sensores IoT já instalados na planta — sem necessidade de limiares manuais, rotulação humana ou hardware adicional.

Diferenciais da solução:

- **Agnóstico ao tipo:** um único sistema atende equipamentos elétricos (com corrente e RPM) e mecânicos (apenas vibração e temperatura), sem reconfiguração.
- **Não supervisionado:** o algoritmo aprende os padrões operacionais de cada equipamento diretamente dos dados (sem necessidade de exemplos rotulados).
- **Baixo custo e escalável:** reaproveita a infraestrutura IoT existente e processa cada equipamento em menos de 14 minutos.

Por que aprendizado não supervisionado?

Primeira tentativa: redes profundas (CNN / Autoencoders).

- Acurácia de treino de 100%, mas os modelos **memorizavam** os padrões do conjunto de treino.
- **Extremamente sensíveis a variações bruscas:** pequenas mudanças nos valores de corrente ou temperatura causavam previsões completamente diferentes (o modelo não entendia o fenômeno, apenas decorava sequências).

Nova solução


Complexidade excessiva para um problema binário. Foi implementado o **K-Means** puro: robusto a variações, interpretável, sem *overfitting* e de treino rápido.

- **Linguagem:** Python 3.11+
- **Dados:** **InfluxDB** (séries temporais para IoT)
- **Processamento:** *Pandas*, *NumPy*, *SciPy* (interpolação PCHIP/KNN)
- **Machine Learning:** *Scikit-learn* (K-Means, MinMax, PCA)
- **Interface:** *CustomTkinter* (GUI para operadores)
- **Visualização:** *Matplotlib* (gráficos 3D), *Plotly* (web)


Visão geral do *pipeline*

Pipeline dual e modular:


- 1 Detecção automática do tipo (elétrico/mecânico).
- 2 Coleta e segmentação.
- 3 Interpolação e tratamento de *outliers*.
- 4 Sincronização e normalização.
- 5 Classificação K-Means.
- 6 JSON de thresholds.



Pipeline de treinamento: fases 1 e 2



Pipeline de treinamento: fases 2 a 6



Coleta e segmentação temporal

- **3 fontes (elétrico):** `validated_default` (20 s), `estimated` (~ 1 min) e `validated_slip` (2 min). Mecânicos usam apenas 2.
- **Download** em `.csv` via *script* Python a partir do InfluxDB.
- **Segmentação por lacunas:** $gaps > 3\text{ h} \Rightarrow$ novos períodos independentes.
- Cada período válido recebe uma **linha temporal uniforme** (grade de 20 em 20 s).

Tratamento das lacunas internas

Intervalos sem dados dentro de um período ($\leq 3\text{ h}$) são preenchidos por **interpolação adaptativa**: *spline* hermitiana (PCHIP) para lacunas curtas ou KNN temporal para lacunas médias, garantindo continuidade na série.

As três fontes de dados (equipamento elétrico)

validated_default (20 s) — temperatura e vibração:

Time (UTC)	object_temp (°C)	vel_rms_x (mm/s)
15/01/2025 10:00:00	45,2	2,1
15/01/2025 10:00:20	45,3	2,2
15/01/2025 10:00:40	45,3	2,1

estimated (~1 min) — corrente e RPM:

Time (UTC)	current (A)	rotational_speed (RPM)
15/01/2025 10:00:15	12,5	1180
15/01/2025 10:01:10	12,6	1182
15/01/2025 10:02:08	12,6	1183

validated_slip (~2 min) — análise espectral:

Time (UTC)	fe_frequency (Hz)	fe_magnitude_0 (mT)	rms (mT)
15/01/2025 10:00:30	1,85	50,7	2,40
15/01/2025 10:02:25	1,86	50,8	2,41
15/01/2025 10:04:20	1,85	50,7	2,39

Sincronização e fusão das tabelas de dados

Dados iniciais — 3 tabelas com frequências distintas (elétrico):

Fonte	Frequência	Atributos principais
validated_default	20 s	magnetômetro, temperatura, vibração RMS
estimated	~1 min	corrente, RPM, vibração estimada
validated_slip	2 min	frequência de escorregamento, harmônicas

Processo de fusão:

- 1 validated_default (20 s) é a **base temporal** de referência.
- 2 estimated é alinhada via *backward-fill* (tolerância de 6 min).
- 3 validated_slip é alinhada via *backward-fill* (tolerância de 3 min).
- 4 Exigência de **> 70%** de sobreposição temporal entre fontes.

Backward-fill



Cada instante sem leitura recebe o **próximo valor futuro** disponível dentro da janela de tolerância, garantindo que só dados já existentes preencham o grid, sem extrapolar valores passados.

Interpolação adaptativa de lacunas

Estratégia por tamanho:


- ≤ 30 min: **PCHIP** (Spline Hermitiana (curva suave, sem oscilações)).
- 30 min–3 h: **KNN** temporal + linear (captura padrões cíclicos locais).
- > 3 h: **não interpola** (novo período independente).

LSTM testada mas sem ganho frente ao KNN (complexidade desnecessária).




Tratamento de *outliers* (IQR)

- IQR com multiplicador conservador (3,0).
- Proteção de inércia: sequências ≥ 10 amostras são **preservadas** (não são ruído).
- Filtro anti-EMI: zera RPM/corrente espúrios (< 2 A).



Normalização robusta

- *MinMax Scaler* para o intervalo $[0, 1]$.
- *Clipping* de *outliers* no percentil 99,5%.
- Preserva a forma e a distribuição; ajusta apenas a escala.
- Equilibra grandezas de escalas distintas.




O coração do sistema: K-Means

Por que não um limiar fixo?

- Vibração residual de máquinas vizinhas.
- Variação da temperatura ambiente.

Configuração:

- $k = 6$ (proporção $\sim 1:2$ entre desligado e ligado, captando transições).
- *score* ponderado pela física.



Centróides: cada *cluster* k do K-Means possui um centróide $\bar{C}_k$, que é o ponto médio (em cada dimensão) de todas as amostras atribuídas àquele grupo. O centróide resume o “perfil típico” de operação daquele grupo.

Score ponderado de cada centróide:

$$S_{\text{elétrico}} = 2,0 \bar{C}_{\text{corr}} + 2,0 \bar{C}_{\text{RPM}} + 1,0 \bar{C}_{\text{vib}} + 0,5 \bar{C}_{\text{temp}}$$
$$S_{\text{mecânico}} = 1,5 \bar{C}_{\text{temp}} + 1,0 \bar{C}_{\text{vib}} + 0,5 \bar{C}_{\text{mag}}$$

- Os *clusters* são ordenados pelo *score*: os **dois de menor valor** são avaliados como candidatos ao estado **DESLIGADO** (perfis de baixa atividade), passando em seguida pela etapa de validação.

Dois candidatos DESLIGADO: design e validação

Design intencional: os dois *clusters* de menor *score* são *sempre* avaliados como candidatos ao estado DESLIGADO, em todos os equipamentos.

Etapas de validação (aplicada a todos):

- Diferença de *score* entre os dois candidatos $< 0,3$.
- Ambos os *scores* $< 0,5$ (baixa atividade absoluta).
- Vibração do 2º candidato $< 1,5$ (nível residual).





Resultado após validação:

- **Na maioria dos casos:** o 2º candidato falha (regime de baixa carga, não repouso) $\Rightarrow$ reclassificado como LIGADO.
- **Evento raro:** ambos sobrevivem $\Rightarrow$ dois perfis distintos de inatividade real (ex: temperatura ambiente alta vs. baixa).

Visualização dos *clusters* via PCA

PCA — Análise de Componentes Principais:


- Reduz as **19 dimensões** originais para 2 (só para visualização).
- **PC1 (38,7%)**: separa LIGADO de DESLIGADO (correlação forte com corrente ($\rho=0,94$) e RPM ($\rho=0,92$)).
- **PC2 (19,4%)**: variações de carga dentro do estado LIGADO.



Nota: o K-Means opera no espaço original (19D/16D); PCA é apenas para visualização.

Análise por intervalo e interface

- Modelo treinado aplicado a novos períodos via InfluxDB.
- Validações: cobertura $> 70\%$, sem *gaps* > 3 h.
- GUI em 3 abas: treino, análise e visualização 3D.
- Calendário restrito (2025+), configuração automática de IP/porta.



Resultados: visão geral

- **5 equipamentos** reais, > **5,4 milhões** de registros (~ 7 meses).
- Classificação binária integral em LIGADO/DESLIGADO.
- *Pipeline* completo por equipamento em **menos de 14 min.**

Equip.	Tipo	DESLIGADO	LIGADO
C ₆₃₆	Elétrico	4,75%	95,25%
C ₆₃₇	Elétrico	4,52%	95,48%
C ₆₄₀	Elétrico	5,64%	94,36%
C ₁₅₁₈	Mecânico	4,76%	95,24%
C ₆₇₀	Mecânico	20,99%	79,01%


Resultados: equipamento elétrico (c₆₃₆)

Cenário:

- Motobomba com sensores de corrente, RPM e vibração.


Resultado:

- Separação clara entre estados.
- LIGADO 95,25% / DESLIGADO 4,75%.



Resultados: equipamento mecânico (c_{1518})

Grafico 1 - Temp x Vib x Tempo — c_{1518}



Desafio:


- Sem dados elétricos.
- Apenas temperatura e vibração.

Resultado:

- Operação quase contínua.
- LIGADO 95,24% / DESLIGADO 4,76%.

Resultados: equipamento mecânico (c₆₇₀)

Grafico 1 - Temp x Vib x Tempo — c₆₇₀



Resultado:


- Maior proporção DESLIGADO entre os mecânicos (21%).
- Discriminação clara pela **inércia térmica**: ao ligar, temperatura e vibração sobem gradualmente.
- No ângulo do 3D os pontos podem parecer sobrepostos.

Reconstrução temporal e horímetro

- Ciclos LIGADO/DESLIGADO ao longo de todo o histórico.
- Cores distinguem dado original de interpolado (PCHIP/KNN).
- Base para **horímetro real** e gestão de manutenção.

Visualizador web interativo das séries classificadas:

<https://evolution-tcc-felipe-costa-lobes-visualizador.hfzba0.easypanel.host/>



Impacto ambiental:

- **Gestão energética:**
identificação precisa de períodos ociosos revela desperdício oculto (equipamentos ligados desnecessariamente).
- **Redução de resíduos:**
manutenção baseada em horas reais evita troca prematura de peças, óleos e lubrificantes.
- **Custo computacional:**
K-Means treina em minutos em hardware modesto, sem GPU (menor consumo energético e computacional de redes profundas).

Impacto social:

- **Segurança operacional:**
monitoramento contínuo antecipa paradas, reduzindo falhas inesperadas que colocam trabalhadores em risco.
- **Democratização:** GUI permite que operadores sem conhecimento de programação treinem modelos e analisem dados.
- **Baixo custo de adoção:**
funciona com sensores já instalados, viável para pequenas e médias indústrias.

Trabalho futuro principal:

- **Online learning:** retreinamento automático e incremental do K-Means, adaptando o modelo continuamente a mudanças graduais nos padrões operacionais (desgaste natural, sazonalidade) — sem necessidade de re-treinar do zero.

Código, dados e visualizador disponíveis publicamente:

https://github.com/felcoslop/TCC_1_FELIPE_COSTA_LOPES

Obrigado!

Perguntas?

Felipe Costa Lopes — Matrícula: 2018019648
Orientadora: Profa. Dra. Gabriela Nunes — UFMG